9/7 · 9/9 강의 · 핵심 한 장으로 이동

기초 상식: 용어와 감각

- **data science** = 수학 · 통계 · 컴퓨터과학이 함께하는 학제간 과학
  - 목표: 데이터에서 새로운 지식 추출
- big data의 **4V**: Volume · Velocity · Variety · Veracity
  - **Viscosity는 아님** (시험에 헷갈리게 냄)
- **sample mean**의 표준오차 (독립·동일분포 표본, 분산 σ²일 때) $\propto 1/\sqrt{N}$
  - N을 100배 하면 표준오차는 $\frac{1}{10}$. 표준오차를 1/10로(정확도 10배) 줄이는 데 데이터 100배 필요
  - 단, 이는 표준오차의 크기 관계이며, 실제 오차가 반드시 같은 비율로 감소하는 것은 아니다 (편향이나 표본 간 의존성이 있으면 달라질 수 있다)
  - 표준오차 4를 1로 줄이려면 $\sqrt{N}$이 4배, 즉 $N = 16$배
- **Shannon entropy** $H = -\sum_i p_i \log_2 p_i$ (약속: $0 \log 0 = 0$)
  - uniform distribution에서 최대: 4칸이면 $\log_2 4 = 2$

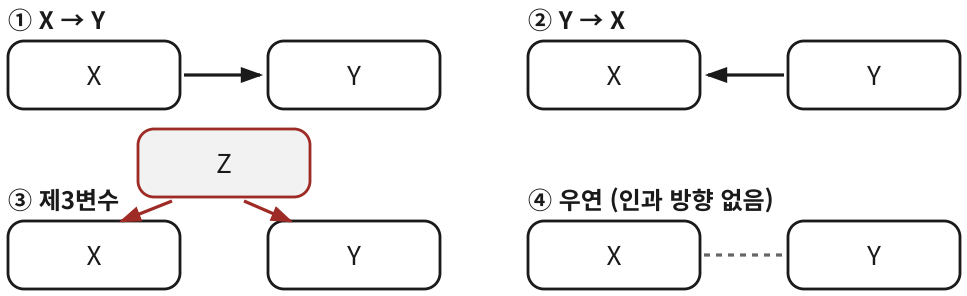
균일 간격 보간 다항식의 함정

- 균일 간격 보간에서는 점의 수를 늘려도 보간 다항식이 참 함수로 수렴하지 않을 수 있다. 예를 들어 Runge 함수에서는 고차 다항식 보간의 양 끝에서 진동이 커질 수 있다. 수렴 여부는 함수와 보간 방식에 달려 있다.
- "점을 많이 찍으면 다항식이 정답에 가까워진다"가 아니다. 주제 6의 신경망 동기로 이어진다.

correlation ≠ causation

상관이 강하다는 말의 대표적인 설명은 **네 가지**다:

- $X \to Y$ (X가 원인)
- $Y \to X$ (방향이 반대)
- **third variable**가 둘 다 움직임
- 우연



강한 상관의 네 가지 설명: 화살표가 곧 인과는 아니다 점선은 관찰된 상관관계를 나타내며, 인과 방향을 의미하지 않는다.

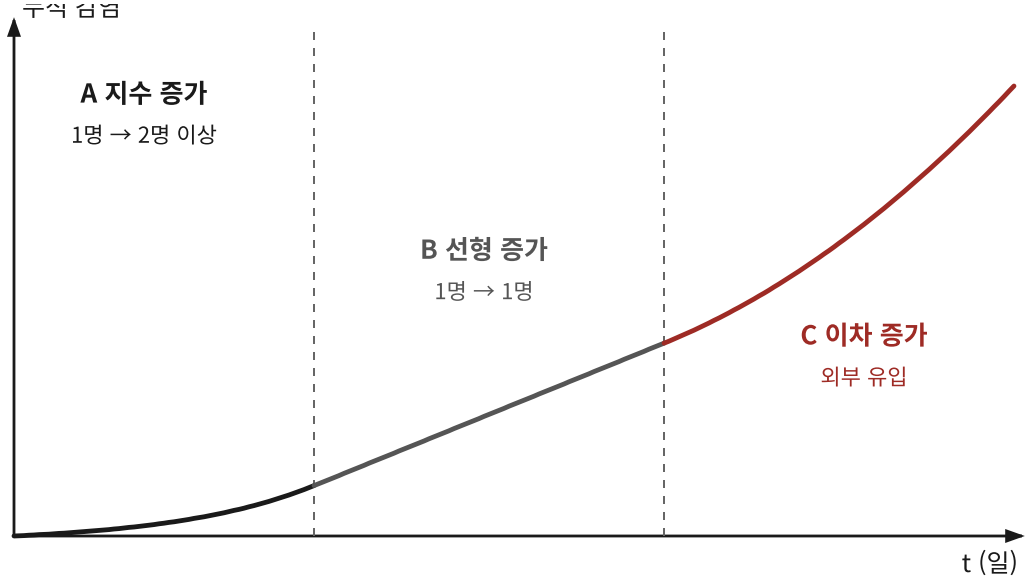
- 인과적 해석을 갖는 DE 모델을 세우려면 변수 간 인과관계와 모델의 구조적 가정이 뒷받침되어야 한다. 상관만으로 인과를 단정하면 안 되며, 상관 데이터만으로 추정한 모델의 예측력이 높더라도 인과적 타당성이 보장되는 것은 아니다.

상관은 있는데 인과가 없는 경우 vs 있는 경우

- **멸치 vs 정어리**: 음의 상관: 경쟁이 아니라 **해양 환경**(산소 최소층, 플랑크톤)이라는 제3변수가 원인
  - → 경쟁 DE 모형은 부적절
- **아이스크림 판매 vs 상어 공격**: 양의 상관: 원인은 **기온**(제3변수)
  - → 이런 데이터로 DE를 세우면 의미 없는 모형
- **접촉 빈도 ↑ → 감염률 ↑**: 상관과 인과가 함께 있어 메커니즘을 해석하는 DE 모형으로 세우기 타당하다. 예측 전용 모형은 인과 없이도 세울 수 있으나 인과적 해석은 할 수 없다.

코로나 데이터 읽기: 세 수치의 정체

- **격리중** = 해당 시점에 격리 중인 확진자 수(집계 기준에 따른 현황값). 일일 신규 확진자 수나 전체 감염자 수와는 다르다
- **확진** = cumulative 확진: 비감소 함수
- **격리해제** = 누적 회복
  - 신규 확진이 발생하면 일정한 시간 지연 후 회복자가 나타날 수 있다. 누적 회복은 회복 사례가 추가될 때 증가하며, 확진과 회복의 관계는 회복 시간 분포와 집계 기준에 따라 달라진다



누적 감염 곡선의 세 구간: 구간마다 사회의 상태가 다르다

- 구간 해석:
  - **A(지수적 증가)**: 일정한 양의 성장률이 유지되는 상황과 부합한다
  - **B(선형적 증가)**: 일정한 규모의 신규 발생이 유지되는 상황과 부합한다
  - **C(가속 증가)**: 외부 유입 증가 등이 가능한 설명이지만, 곡선 형태만으로 원인을 확정할 수 없다
- 하루 단위 이산 데이터로 연속 DE를 세우는 이유 세 가지:
  - 숨은 dynamics 이해
  - 예측
  - parameter estimation

이산 모형 → DE, 방법 1: 해를 연속화

- 이산 규칙의 해를 먼저 구한 뒤 연속 변수로 바꾼다: $I_n = 2^n$, 단위 시간 τ, $t = n\tau$에 $n = t/\tau$ 대입
- 일반형으로 쓰면: $N_{n+1}=aN_n$이면 이산 해는 $N_n=N_0\,a^n$. 한 스텝을 단위 시간으로 정하고 $N(t)=N_0\,a^t$로 확장하면 $a>0$일 때 $dN/dt=(\ln a)N$. 한 스텝의 실제 시간 길이가 τ이면 $N(t)=N_0\,a^{t/\tau}$, 따라서 $k=\ln(a)/\tau$이다

$$I_n = 2^n \;\Rightarrow\; I(t) = 2^{t/\tau} = e^{kt}, \quad k = \tfrac{\ln 2}{\tau}$$

이산 모형 → DE, 방법 2: 변화율을 직접

- $I_{n+1} - I_n = \beta I_n$. 매 스텝 2배씩이면 $\beta = 1$, 3배씩이면 $\beta = 2$
- 시간 간격을 Δt로 바꾸면 증가량은 그에 비례해 작아져야 한다: $\beta(\Delta t) = k\,\Delta t$ (1차 근사; 정확히는 $\beta(\Delta t) = e^{k\Delta t} - 1$)
- 매 스텝(간격 τ) 2배이면 $\beta(\tau) = 1$. 이를 정확한 관계 $\beta(\tau) = e^{k\tau} - 1$에 대입하면, 방법 1과 같은 DE가 되는 조건: $k = r = \ln 2/\tau$
- 로그는 자연로그. 단위(일/주)를 맞춘다

2일마다 3배로 늘면, 2배가 되는 데 며칠?

① **성장률 계산.** $I_n = 3^n, \tau = 2$ → 연속화하면 $I(t) = 3^{t/2} = e^{rt}, r = \ln 3/2 \approx 0.549$
방법 1: 이산 해를 연속 함수로 옮긴다

② **2배 시간에 대입.** $e^{rT} = 2 \to T = \ln 2/r = 2\ln 2/\ln 3 \approx 1.26$일
"몇 배가 되는 시간" 유형은 항상 $T = \ln(m)/k$

$T = \dfrac{2\ln 2}{\ln 3} \approx 1.26$일. 매일 2배($\tau = 1$)면 $k = \ln 2 \approx 0.693$

관련 과제 풀이

- HW1 문제 2: 이산 인구 자료의 연속시간 미분방정식 모형