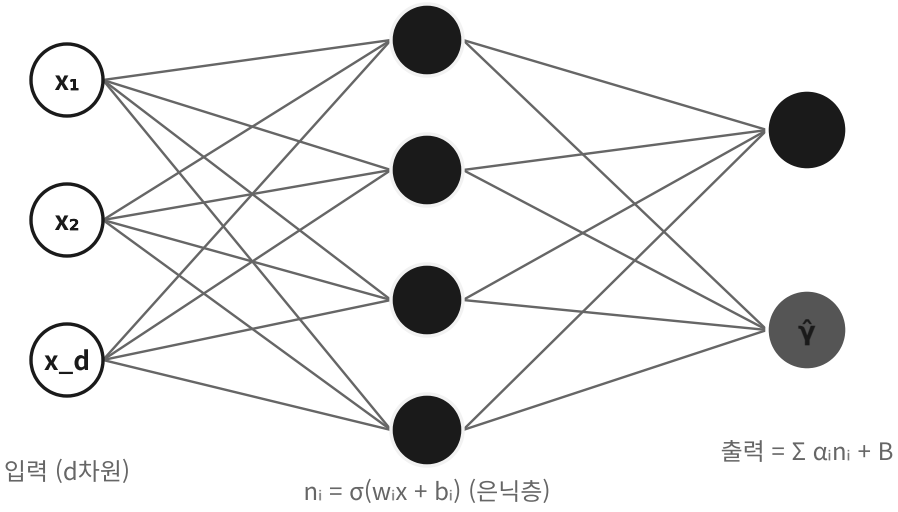
9/30 · 10/7 · 10/12 강의 · 핵심 한 장으로 이동

neural network = 함수

- 단일 은닉층: 입력 x, neuron $n_i = \sigma(w_i x + b_i)$ — w는 weight, b는 bias, σ는 activation
- 출력은 neuron의 선형합 + bias
- activation은 선형 변환 뒤에 적용하는 함수이며, 비선형 activation을 사용하면 신경망이 비선형 함수를 표현할 수 있다. 비선형 activation이 없으면 bias가 포함된 여러 층을 합성해도 아핀 함수 f(x)=Wx+c만 표현할 수 있으므로 일반적인 비선형 함수를 표현할 수 없다
- 벡터 입력 $\vec{x} \in \mathbb{R}^d$: $N_i = \sigma(\vec{w}_i^T \vec{x} + b_i)$. 출력이 둘이면 각각 다른 weight와 bias: $\hat{\beta} = \sum \alpha_{\beta,i} N_i + B_\beta$, $\hat{\gamma} = \sum \alpha_{\gamma,i} N_i + B_\gamma$



입력 → 은닉층(neuron마다 weight·bias·activation) → 선형합 출력

activation 두 가지

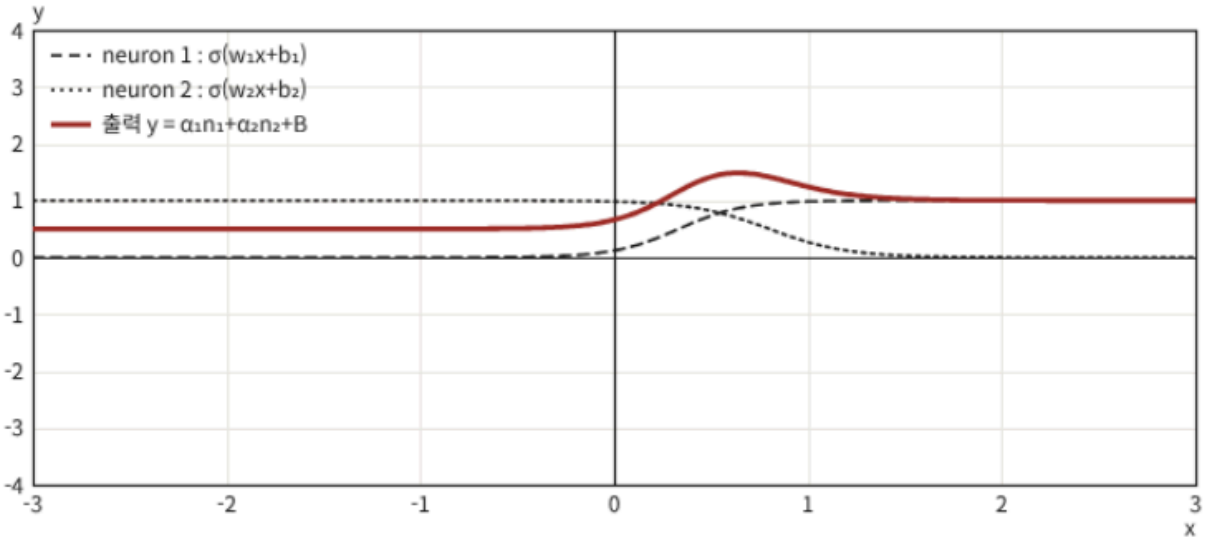
· sigmoid $\sigma(x) = \frac{1}{1+e^{-x}}$: 치역 $(0,1)$, $\sigma(0) = \frac{1}{2}$, $\sigma(x) + \sigma(-x) = 1$

· ReLU $= \max(0, x)$: 치역 $[0, \infty)$, 0에서 미분 불가이나 연속

미지수 개수 세기 (입력 d차원, neuron N개, 출력 2개):

$dN + N + 2N + 2 = (d+3)N + 2$ 구조를 구분하면: 출력 1개이면 dN+N+N+1=(d+2)N+1개, 출력 2개이면 dN+N+2N+2=(d+3)N+2개이다. d=1, N=2이면 각각 7개와 10개다

은닉층 하나 = 선형 → 활성화 → 선형 합

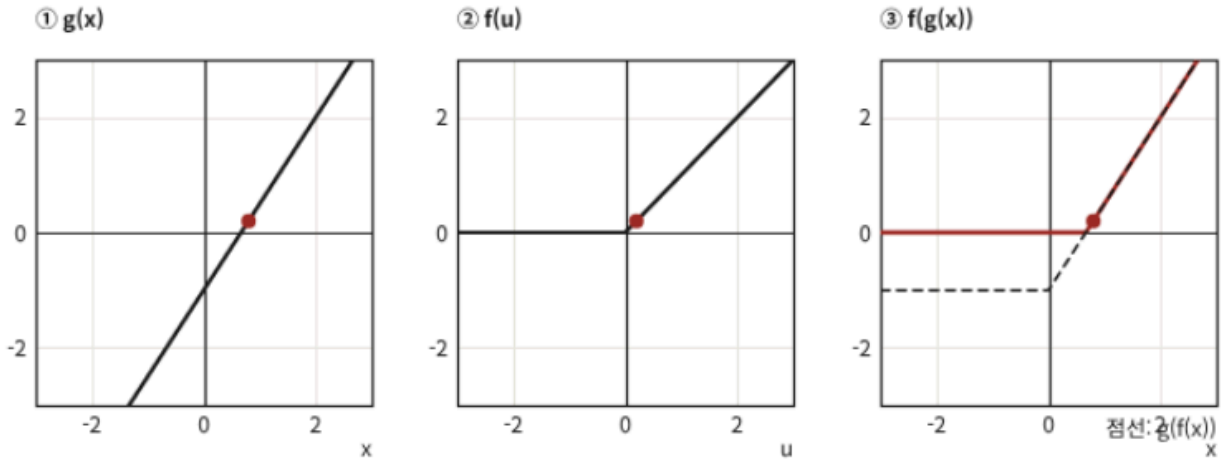


기본값: w_1 6.0 · b_1 -2.0 · w_2 -5.0 · b_2 4.0 · α_1 1.5 · α_2 1.0 · B -0.5

구조: x → **선형**(wx+b) → **비선형 σ** → **선형 합**(α·n+B) = 합성함수 ｜ 미지수 : w,b가 2개씩 + α 2개 + B = **7** = (d+2)N+1 (d=1, N=2)

$\sigma(wx+b)=\sigma(w(x-b'))$, $b'=-b/w$: neuron 1 중심 b'_1 = **0.33**, neuron 2 중심 b'_2 = **0.80** (그 점에서 σ=½). |w|가 클수록 가파른 계단(step)에 가까워진다.

합성함수 f∘g: 안쪽과 바깥쪽, 순서가 중요



기본값: a 1.5 · b -1.0 · 입력 x 0.80

---

x=0.800 → g(x)=0.20000 → f(g(x))=0.20000

g(f(x))=0.20000

연쇄법칙: $f'(g(x))g'(x)$=1.500000 · 수치 미분=1.500000 (일치)

합성 f∘g가 정의되려면 g(x)가 f의 정의역에 속해야 한다. 연쇄법칙은 g가 x에서, f가 g(x)에서 미분 가능할 때 적용한다. 유한 차분은 수치 검산이며 증명은 아니다.

Weierstrass와 UAT

Weierstrass (1885). $f \in C[a,b]$이면 임의의 $\varepsilon > 0$에 대해 다항식 f_N이 있어 $\|f - f_N\|_\infty < \varepsilon$.

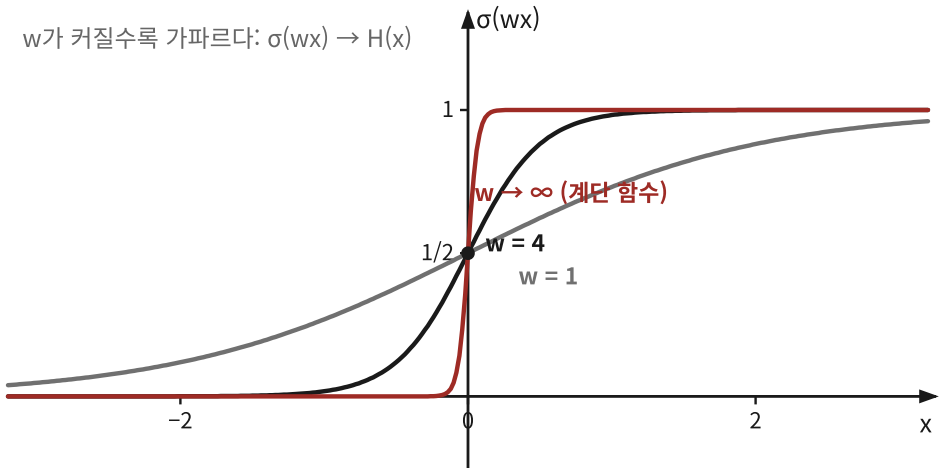
UAT (Cybenko 1989). $f \in C[a,b]$이면 임의의 $\varepsilon > 0$에 대해 α_i, w_i, b_i, B(와 N)가 존재하여

$$y(x) = \sum_{i=1}^{N} \alpha_i \, \sigma(w_i x + b_i) + B, \qquad \|f - y\|_\infty < \varepsilon$$

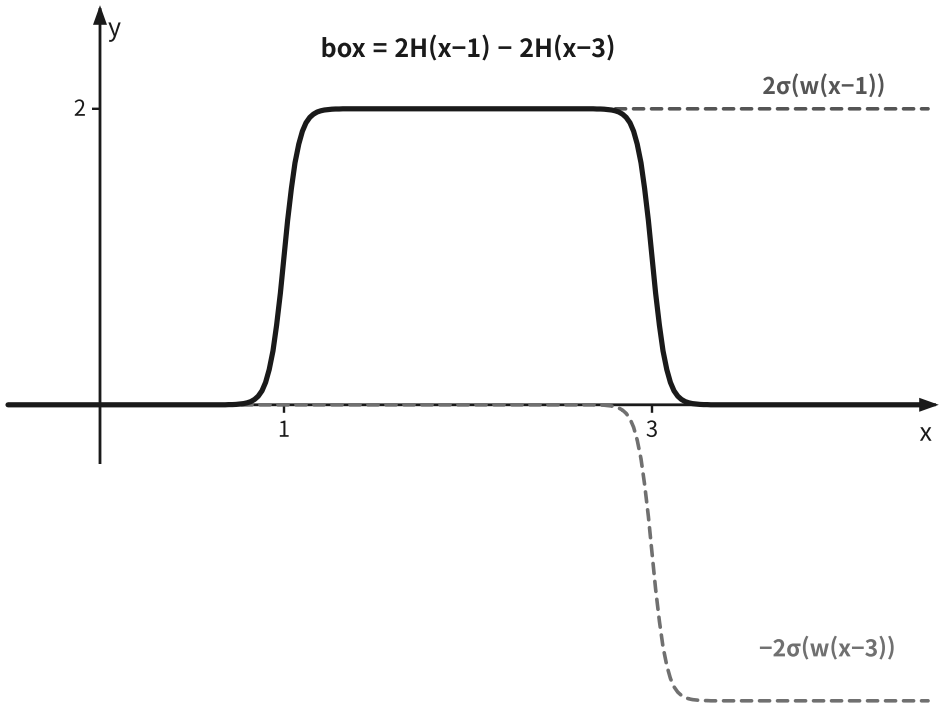
- $\|f - y\|_\infty = \max_{x \in [a,b]} |f(x) - y(x)|$: sup norm
- 가정은 연속뿐. 꺾인 점이 있어도 된다
- 두 정리는 연속함수를 임의의 정확도로 균일 근사할 수 있다는 결론이 유사하다. 다만 Weierstrass 정리는 다항식으로, UAT는 적절한 활성화함수를 갖는 신경망으로 근사할 수 있음을 보이며, 근사함수 클래스와 성립 조건이 다르다. 둘 다 **존재성만 말하고 파라미터를 구하는 방법은 알려주지 않는다**. 다층(MLP)에도 성립

UAT 증명 아이디어: sigmoid를 계단과 블록으로

- $\sigma(wx + b) = \sigma\big(w(x - b')\big), b' = -b/w - w$는 scaling(클수록 가파름), b'은 translation(값이 $\frac{1}{2}$인 중심의 위치)
- $w \to \infty$이면 $\sigma(w(x - b')) \to H(x - b')$: step function(Heaviside)
- step의 차 $H(x) - H(x-1)$은 $[0,1]$에서만 1인 box → 높이를 바꿔 합치면 piecewise constant 근사. ε가 작을수록 neuron이 더 필요



w가 커질수록 sigmoid가 step function에 가까워진다



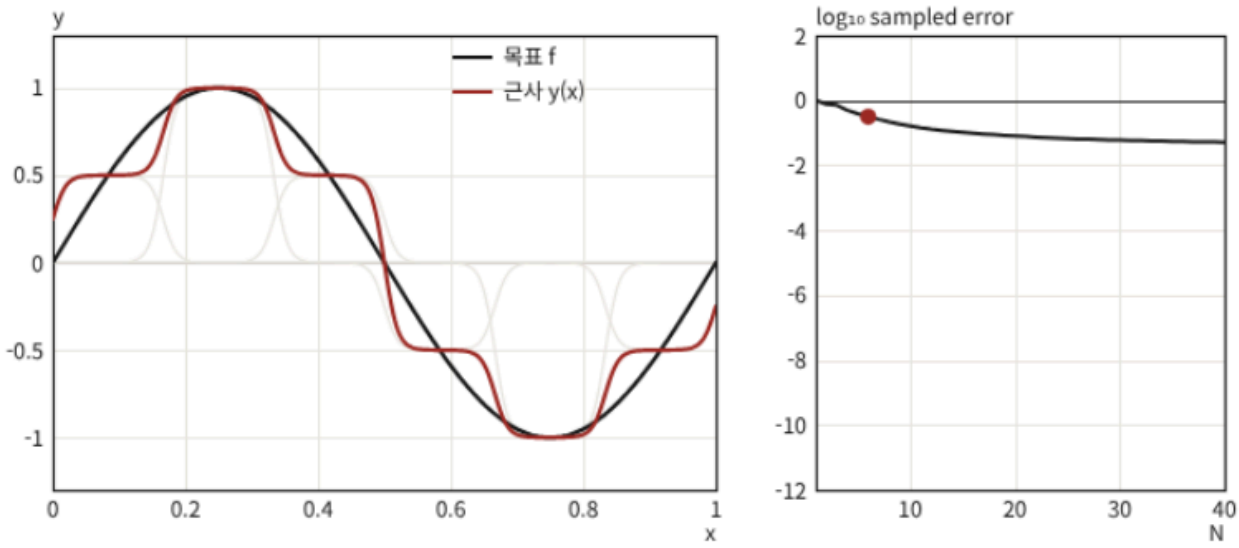
step 두 개의 차로 만든 box. box들의 합이 조각 상수 근사

예. 구간 $(1, 3)$에서 값 2, 나머지 0 → $2H(x-1) - 2H(x-3)$. 근사: $y = 2\sigma(w(x-1)) - 2\sigma(w(x-3))$, w 크게.

주의. 계단함수의 차로 box 함수를 구성할 수 있고 sigmoid의 큰 기울기는 경계 전이를 점점 가파르게 근사하지만, 불연속 box 함수 자체는 연속 신경망으로 균일 근사할 수 없다 (경계 부근의 균일 오차는 임의로 작아지지 않는다). UAT의 균일 근사를 설명하려면 연속 목표함수에 대해 서술해야 한다.

예. $\sigma(3x-6) = \sigma(3(x-2)) - w = 3,\ b' = 2, x = 2$에서 $\frac{1}{2}, w \to \infty$이면 $H(x-2)$.

UAT의 구성: 계단 두 개의 차(box)로 조각 상수 근사



기본값: N 6 · log₁₀ w w=100

그림의 목표 함수는 f(x) = sin(2πx), x ∈ [0, 1]이다. 이를 N = 6개 구간으로 나누고, 각 구간 중앙의 f 값을 높이로 하는 box들의 합으로 근사한 뒤, [0, 1]의 801개 표본에서 측정한 최대 절댓값 오차는 **0.316242**이다. 이 값은 유한 표본에서 측정한 최댓값이며, 연속 구간 전체의 sup norm 오차를 증명하지 않는다.

Sigmoid neuron 12개 · w=100

각 box의 높이는 구간 중앙의 f 값이다. sigmoid 두 개의 차로 매끄러운 계단 근사를 만들며, 유한한 w에서는 경계가 완전히 날카롭지 않다. 끝점의 출력도 별도로 확인해야 한다.

오른쪽 그래프는 같은 801개 표본에서 구한 근사 오차를 N에 따라 나타낸다. 로그 그래프에서는 0 오차를 그릴 수 없으므로 1e-12를 시각화에만 사용한다. 수치 하한을 실제 오차로 해석하면 안 된다.

UAT는 적절한 신경망 파라미터가 존재한다는 정리이지, 이 구성의 오차가 항상 단조 감소한다거나 학습 알고리즘이 그 파라미터를 찾는다는 보장은 아니다. 유한 표본의 최댓값 역시 연속 구간 전체의 sup norm을 증명하지 않는다.

S, I 데이터로 β, γ 찾기

- **신경망 방법:** 격자(예 $\beta \in [\frac{1}{7}, \frac{1}{3}], \gamma \in [\frac{1}{14}, \frac{1}{7}]$ 위의 $7 \times 7 = 49$ 점)마다 SIR을 풀어 $\{S_i, I_i\}$를 만들고, 신경망이 $(S, I) \mapsto (\beta, \gamma)$를 내도록 제곱오차 손실을 최소화. 시뮬레이션 궤적의 여러 시점 관측을 쓴다 — 단일 시점의 (S, I)만으로는 모수가 식별되지 않을 수 있다
- **직접 풀기:** S, I와 변화율(이웃한 두 날의 차분으로 근사)이 모두 데이터로 주어지면 β, γ에 대해 선형 이다

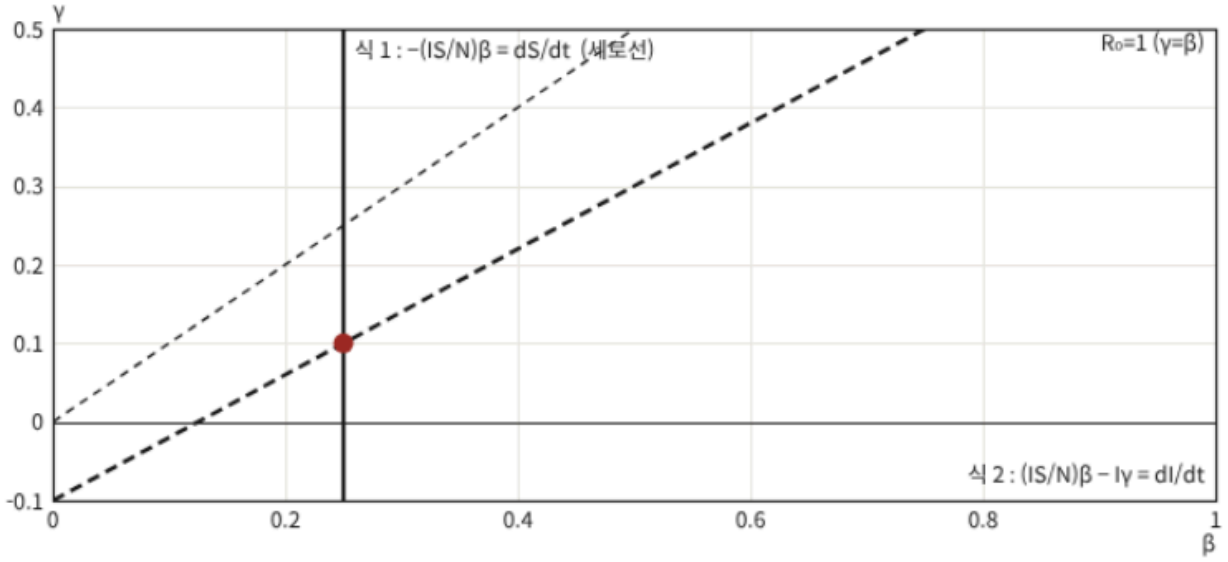
$$\begin{pmatrix} -IS/N & 0 \\ IS/N & -I \end{pmatrix} \begin{pmatrix} \beta \\ \gamma \end{pmatrix} = \begin{pmatrix} dS/dt \\ dI/dt \end{pmatrix}$$

- $\det A = \frac{I^2 S}{N} \neq 0$ $(S, I > 0)$이므로 역행렬이 있다

- γ는 $\frac{dR}{dt} = -\frac{dS}{dt} - \frac{dI}{dt} = \gamma I$에서도 나온다
- 여러 날이면 식이 쌓여 $A\theta = b$ → least squares $A^T A\,\theta = A^T b$로 푼다

예 ($N = 100,\ S = 80,\ I = 10,\ dS/dt = -2,\ dI/dt = 1$): $IS/N = 8$. $-8\beta = -2$ → $\beta = \frac{1}{4}$; $8\beta - 10\gamma = 1 \rightarrow \gamma = \frac{1}{10}$. $R_0 = 2.5 > 1$. 현재 S/N=0.80이므로 유효재생산수 R_eff=βS/(γN)=2.00>1이다. 따라서 현재 시점에서는 감염자가 증가한다. 다만 기본 SIR 모형에서 R_0>1이 유행의 무한한 지속을 보장하는 것은 아니다.

S, I, 변화율로부터 β, γ 풀기 (2×2 선형계)



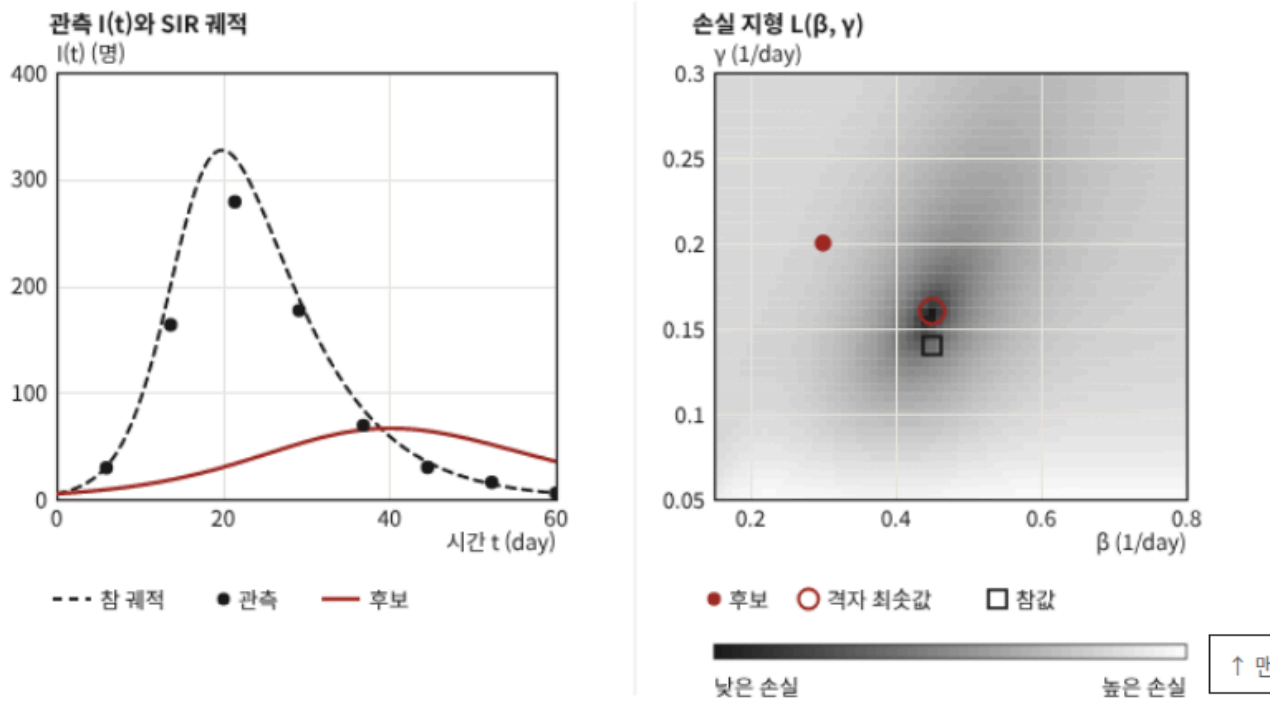
기본값: N 100 · S 80 · I 10 · dS/dt -2.0 · dI/dt 1.0

행렬 A = [−IS/N , 0 ; IS/N , −I] = [−8.00 , 0 ; 8.00 , −10], **det A = I²S/N = 80.00 ≠ 0** (S,I>0) → 역행렬 존재

β = 0.250, **γ = 0.100**, R_0 = β/γ = 2.50 > 1, 유효재생산수 R_eff=βS/(γN)=2.00 > 1 → 현재 시점에서는 감염자가 증가한다 (R_0>1이 유행의 무한한 지속을 보장하는 것은 아니다)

두 식의 그래프(선)의 교점이 (β,γ). 노트 예 N=100,S=80,I=10,dS/dt=−2,dI/dt=1 → β=1/4, γ=1/10, R_0=2.5. 날짜가 여러 개면 식이 쌓여 최소제곱 $A^TA\theta=A^Tb$.

손실 지형: 제곱오차를 최소화하는 (β, γ) 찾기



기본값: 후보 β (1/day) 0.300 · 후보 γ (1/day) 0.200 · 관측 시점 수 k 8 · 상대 잡음 σ 0.12

후보 손실 L = **100800 people²** · R_0 = β/γ = 1.500 (참값 3.214)

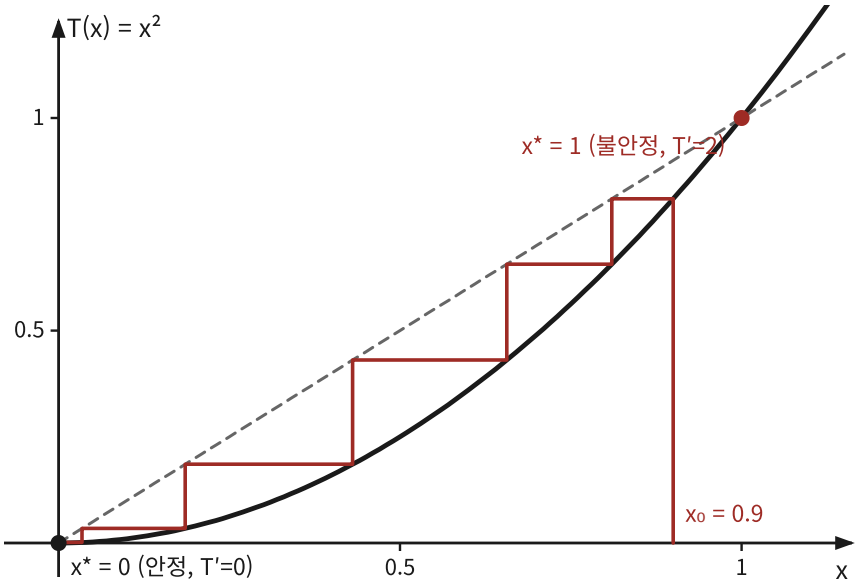
격자 최솟값 L = 165.3 people² · ($\hat{\beta}$, $\hat{\gamma}$) = (0.450, 0.160) 1/day · 참값과의 거리 = 0.0200 1/day

관측 시점이 늘면 모수 조합을 구분하기 쉬워질 수 있습니다. 잡음과 관측 시점의 배치도 추정 결과에 영향을 줍니다.

loss landscape(손실 지형): 각 (β, γ)에서 SIR 모형(감수성–감염–회복)의 궤적을 구하고, 관측 I(t)와의 squared-error loss(제곱오차 손실)를 합산합니다. 손실이 가장 작은 격자점은 least squares(최소제곱) 추정값의 근사입니다.

불균형과 불완전 데이터: I가 없을 때

- **unbalanced**: 종류별 데이터 양이 크게 다름 → 부족한 쪽 데이터를 추가
- **incomplete**: 필요한 정보 일부가 빠짐 (예: S만 있고 I 없음)
- I가 없을 때: $I = -\frac{N}{\beta S}\frac{dS}{dt}$에 β가 필요한데 β가 찾는 값이다 → **순환**. 그래서 추측 → 예측 → 갱신을 반복한다



두 네트워크의 추측-갱신 반복: 신경망 1이 I를 예측, 신경망 2가 β,γ를 갱신

- 신경망 1: $(S, \beta_n, \gamma_n) \mapsto \hat{I}_n$, 신경망 2: $(S, \hat{I}_n) \mapsto (\beta_{n+1}, \gamma_{n+1})$. 합성을 T라 하면 $(\beta_{n+1}, \gamma_{n+1}) = T(\beta_n, \gamma_n)$
- 두 신경망이 실제 관계를 정확히 구현한다면, 진짜 값에서 시작하면 진짜 I가 재구성되어 $(\beta^*, \gamma^*) = T(\beta^*, \gamma^*)$ → 진짜 모수는 T의 고정점. 수렴 보장은 Banach 정리(T가 contraction일 때)
- 예: $N = 1000,\ S = 800,\ \frac{dS}{dt} = -10$이면 $\beta = 0.25$일 때 $\hat{I} = 50$, $\beta = 0.2$로 잘못 잡으면 62.5 ($\hat{I} \propto 1/\beta$)

고정점 존재성과 유일성

- 고정점 문제: $x = T(x)$인 x^* 찾기. 예 $T(x) = x^2$: $x^* = 0$ 또는 1

Thm 1 (존재). $T : [a, b] \to [a, b]$가 연속이면 $T(x^*) = x^*$인 $x^* \in [a, b]$이 존재한다 (충분조건).

증명: $T(a) = a$ 또는 $T(b) = b$이면 끝. 아니면 $T(a) > a,\ T(b) < b.$
$H(x) = T(x) - x$는 연속이고 $H(a) > 0 > H(b)$이므로 intermediate value theorem로 $H(x^*) = 0.$

Thm 2 (유일). 위에 더해 T가 미분가능하고 모든 x에서 $|T'(x)| < 1$이면 고정점은 하나뿐이다.

증명(귀류): $x^* \neq y^*$가 둘이면 mean value theorem(MVT)로
$|x^* - y^*| = |T'(\xi)| \cdot |x^* - y^*|$인데 $|T'(\xi)| < 1$이라 모순.

예: $T(x) = x^2$ on $[0, 1]$. 존재하지만 유일하지 않다

- 연속이고 $[0, 1]$을 $[0, 1]$로 보냄 → Thm 1으로 존재. $x^2 = x \to x = 0, 1$ — **둘이므로 유일하지 않다** ($T'(1) = 2 > 1$이라 Thm 2 조건 깨짐)
- 반복 $x_{n+1} = x_n^2$: $x_0 = \frac{1}{2} \to \frac{1}{4} \to \frac{1}{16} \to 0,$
  $x_0 = 0.9 \to 0.81 \to 0.6561 \to 0.4305 \to 0.1853 \to 0$
- $x_0 = 1$이면 1에 머뭄, $x_0 = 1.5$이면 발산
- $T'(0) = 0$은 끌어당기고 $T'(1) = 2$는 밀어낸다. **고정점에서의 기울기가 안정성을 결정**
- 주의: 이 판정은 고정점 x*에서의 도함수를 기준으로 하는 국소 안정성 판정이다. |T′(x*)|<1이면 고정점은 국소적으로 끌어당기고, |T′(x*)|>1이면 국소적으로 불안정하다. |T′(x*)|=1이면 이 판정만으로 결론을 내릴 수 없으며, 모든 초기값에서의 수렴을 보장하려면 Banach 정리와 같은 추가 조건이 필요하다

contraction과 Banach 고정점 정리

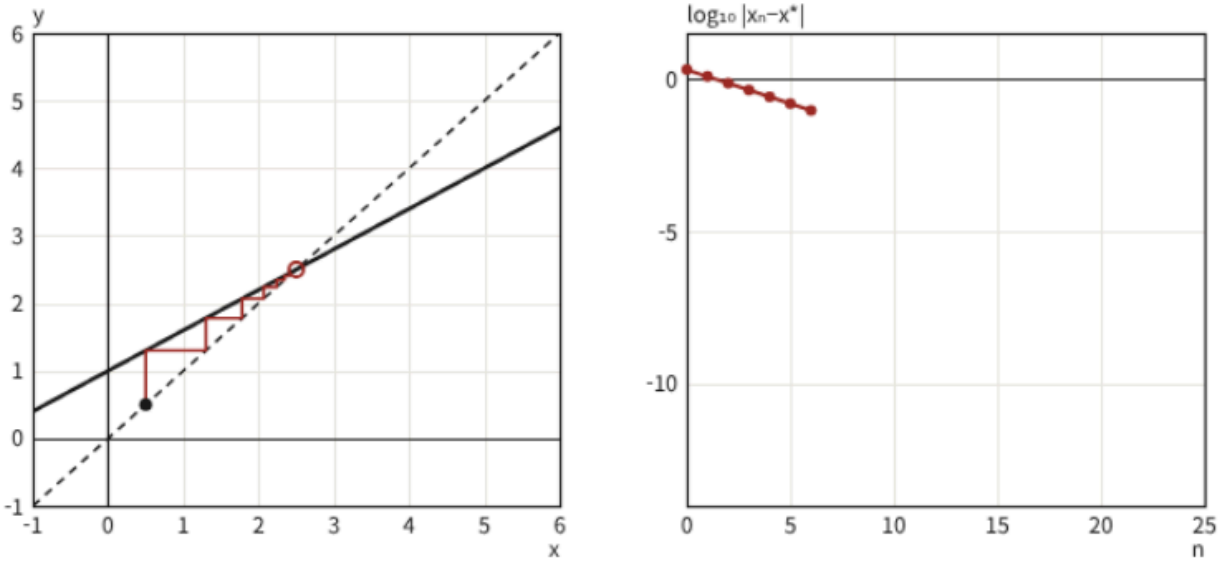
- **metric space** (X, d): $d \geq 0$(같을 때만 0), $d(x,y) = d(y,x)$, $d(x,z) \leq d(x,y) + d(y,z)$. 실수에서는 $d = |x - y|$
- **contraction**: 상수 q, $0 \leq q < 1$이 있어 모든 x, y에 대해 $d(Tx, Ty) \leq q\, d(x,y)$. q는 x, y와 무관한 1 미만 상수

> **Thm 3 (Banach).** (X, d)가 완비(complete) 거리공간이고 $T : X \to X$가 contraction이면 고정점 x^*가 **하나** 존재하고, 임의의 x_0에서 고정점 반복 $x_{n+1} = T(x_n)$이 x^*로 수렴한다. 오차 $d(x_n, x^*) \leq q^n\, d(x_0, x^*)$.

- 증명 뼈대: $d(x_{n+1}, x_n) \leq q^n d(x_1, x_0) \to \{x_n\}$은 Cauchy sequence → 완비성으로 극한 x^* 존재, T가 연속이므로 $x^* = \lim T(x_n) = T(x^*)$. 유일성: 고정점이 둘이면 $d(x^*, y^*) \leq q\, d(x^*, y^*) \to (1-q)d \leq 0 \to d = 0$
- T가 미분가능이면 MVT로 $|T(x) - T(y)| \leq (\sup |T'|)\, |x - y| \to$ $q = \sup |T'| < 1$이면 contraction

정리 3형제 정리: Thm 1: 연속 ⇒ 존재. Thm 2: $|T'| < 1$ ⇒ 유일. Thm 3: contraction ⇒ 존재 + 유일 + 반복 수렴.

고정점 반복과 수축: 오차가 Lⁿ으로 준다



기본값: a 0.60 · x₀ 0.50 · 반복 n 6

---

xₙ = **2.406688** · 고정점 x* = 2.500000

구간 I=[-1, 6] · 자기 사상: **충족** · 수축 조건 L=0.6000 **< 1**

두 조건 모두 확인됨: Banach 정리의 유일 고정점·수렴 결론 적용 가능.
선형 함수에서는 |a|<1이면 수축이다. 고정점이 존재하는 경우에도 수축 조건을 별도로 확인해야 한다.
이 구간에서는 Banach 정리의 오차 상계가 적용된다.
고정점 정리는 자기 사상과 수축 조건을 모두 요구한다. 조건 실패는 정리의 적용 실패이지, 그 자체로 고정점의 부재나 반복의 발산을 증명하지 않는다.

신경망 T의 contraction 조건

- $T(x) = \sum_{i=1}^{N} \alpha_i \sigma(w_i x + b_i) + B$: σ가 연속이라 T도 연속이고, σ 값이 0과 1 사이라 치역이 유계 → 충분히 큰 $[a, b]$에서 $T([a, b]) \subset [a, b]$ → Thm 1로 고정점은 항상 존재

sigmoid의 Lipschitz 상수 $\frac{1}{4}$와 삼각부등식으로

$$|T(x) - T(y)| \leq \tfrac{1}{4} \sum_i |\alpha_i w_i| \, |x - y|$$

$\frac{1}{4} \sum |\alpha_i w_i| < 1$이면 T는 contraction → Banach: 고정점 유일 + 반복 수렴. b_i, B는 조건에 안 들어오고, **충분조건일 뿐**이다. 다층(MLP)은 층별 Lipschitz 상수의 곱이 상계.

① **예 1.** $T(x) = 0.8\sigma(3x - 1) - 0.4\sigma(2x + 1) + 0.5$

$\frac{1}{4}(0.8 \cdot 3 + 0.4 \cdot 2) = 0.8 < 1$ → contraction, 오차 $\leq 0.8^n \, d(x_0, x^*)$

② **예 2.** $T(x) = a\sigma(3x) + 1$

$\frac{1}{4}|a| \cdot 3 < 1 \iff |a| < \frac{4}{3}$ — 이 단일 sigmoid 예에서는 최적 Lipschitz 상수가 3|a|/4이므로, $\mathbb{R}$ 전체에서 contraction의 필요충분조건이다.

관련 과제 풀이

- HW3 문제 5: 신경망으로 SIR 파라미터 역추정
- HW4 문제 2: 두 네트워크와 고정점 반복의 함정
- HW4 문제 3: $x_{n+1} = x_n^2$ 반복
- HW4 문제 4: 단일층 신경망 사상의 축소 조건