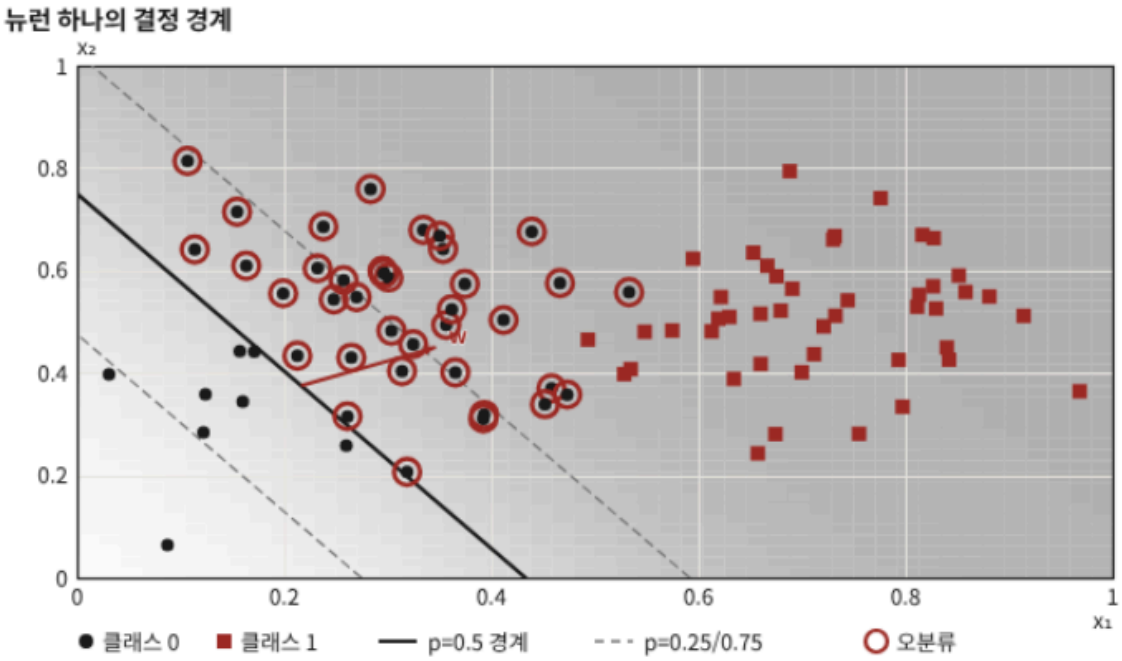
10/21 강의 · 핵심 한 장으로 이동

신경망과 선형 연산자

- **external operator**: 관련 필드들 사이의 mapping. 입력 X가 출력으로 사상된다
- 이미지는 2D 행렬(x축, y축 위의 intensity). grayscale = 2D intensity 행렬
- MLP 예: 입력 이미지 → 층마다 반복, $h^{(k+1)}$은 이전 층의 함수, 총 n층 → 출력은 분류 라벨(예: "cat")

뉴런 하나의 결정 경계: 직선 하나로 두 클래스 나누기



기본값: 법선 방향 θ (도) 30° · 크기 |w| 8.0 · 경계 위치 d 0.38 · 클래스 중심 거리 0.40

현재 표본 정확도 58.9% · 오분류 37/90

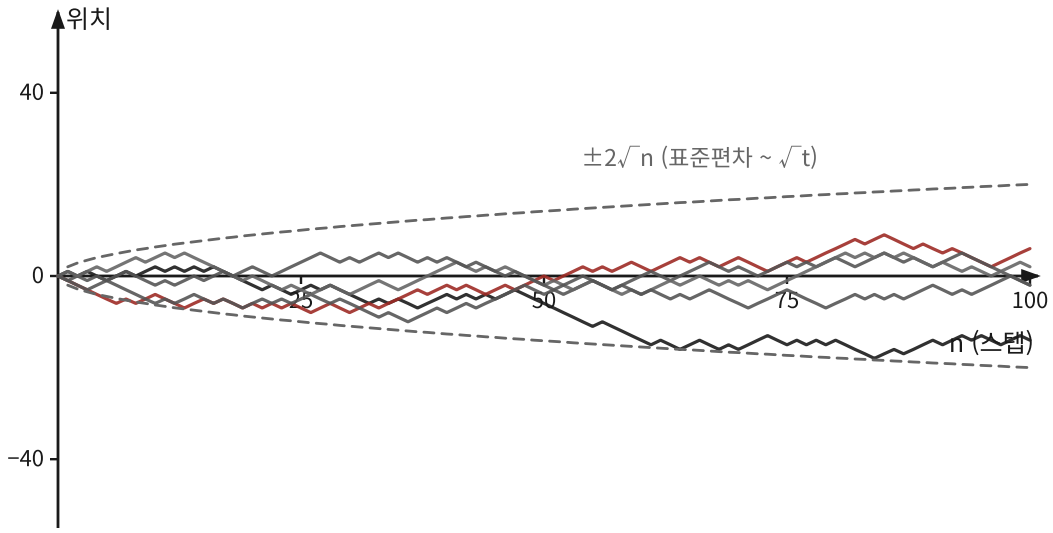
두 클래스 중심의 sigmoid 출력 p_0 = 0.746 · p_1 = 0.979 · 같은 표본 격자 탐색 최고 정확도 (|w|=12, θ 3°·d 0.014 간격, d −0.2~1.2) 98.9%

θ는 경계의 법선 방향 각도(경계 직선의 방향각은 θ+90°), d는 원점에서 경계까지의 거리를 바꿉니다. |w|는 경계를 고정한 채 sigmoid 출력의 전이 가파름만 바꿉니다.

뉴런 하나의 sigmoid output(시그모이드 출력)은 p=σ(w·x+b)입니다. 아래에서는 법선 방향 각도 θ·크기 |w|·위치 d로 w와 b를 나타냅니다. p≥0.5이면 클래스 1, 그렇지 않으면 클래스 0으로 분류합니다. MLP(다층 퍼셉트론)는 선형 연산과 activation(활성화 함수)을 반복해 분류 라벨을 냅니다.

random walk

- 시각 $t = 0$에 위치 0에서 출발. 매 스텝 오른쪽 또는 왼쪽으로 **반드시** 움직인다(제자리 없음). 시간 간격 Δt, 공간 간격 Δx
- 오른쪽 A번, 왼쪽 B번: 총 $k = A + B$ 스텝, 위치 $n = A - B$
- 경로의 수 $\binom{k}{A}$, 전체 가능한 경로 2^k → 위치 n에 도달할 확률 $\binom{k}{A}/2^k$ (k+n이 홀수면 0). 여기서 A=(k+n)/2, B=(k−n)/2이고, A, B가 모두 0 이상의 정수일 때만 그 확률을 가지며 그렇지 않으면 확률은 0이다. 특히 |n|≤k이고 k+n이 짝수여야 도달 가능하다. 단, 이 확률은 대칭 random walk(p=q=1/2)인 경우의 식이다. 오른쪽으로 이동할 확률이 p, 왼쪽으로 이동할 확률이 q=1−p인 일반의 경우에는 P(X_k=nΔx)=C(k,A)p^A q^B이다.

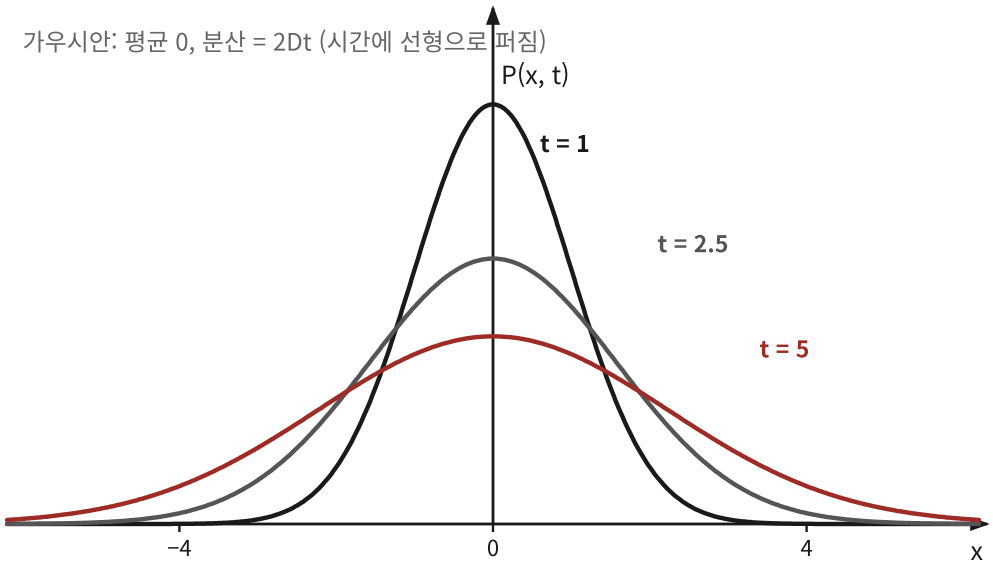


random walk 경로들. 모두 0에서 출발해 좌우 무작위 스텝

---

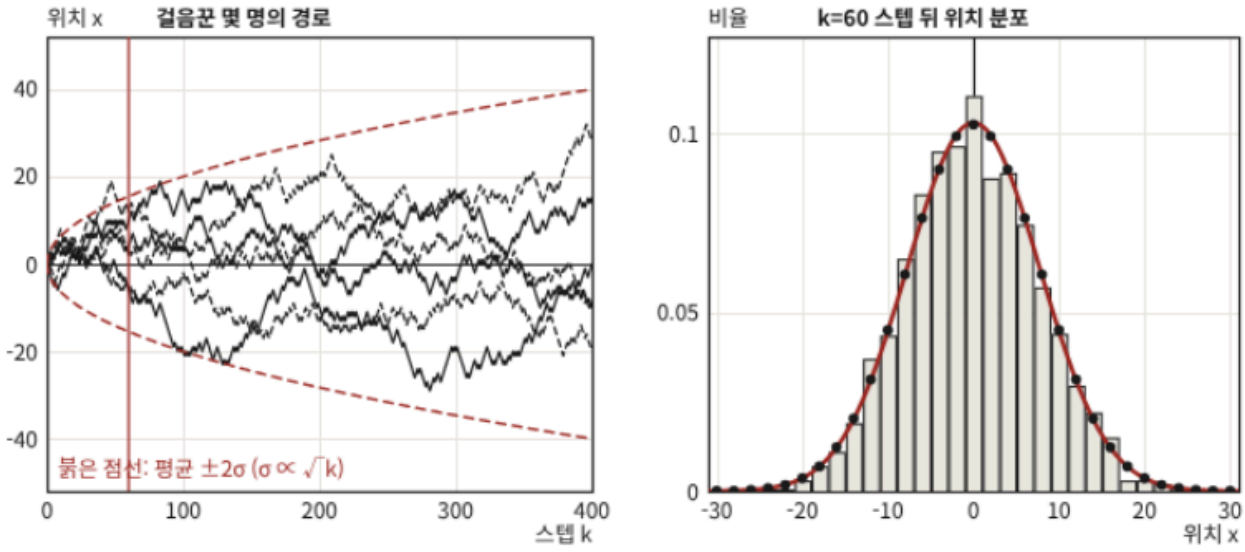
diffusion 과정과 variance

- 100명 시뮬레이션: 모두 중앙에서 출발해 매 스텝 좌우로 움직이면 대부분 가운데에 남고, 분포는 시간에 따라 퍼진다
- 분산은 시간에 선형으로 성장: $\mathrm{Var} \sim t$



시간이 지날수록 퍼지는 위치 분포. 평균은 0, 분산은 t에 비례

random walk: 분산은 시간에 선형 (Var = 2Dt)



기본값: 스텝 수 k (시간 t=kΔt) 60 · 오른쪽 확률 p 0.50 · 공간 간격 Δx 1.0

---

k = **60**, 걸음꾼 2000명 | 평균 : 표본 -0.16 · 이론 (2p−1)kΔx = 0.00 | 분산 : 표본 **58.54** · 이론 4p(1−p)kΔx² = **60.00**

검은 점 = 정확한 확률 $C(k,A)p^Aq^B$ (A=오른쪽 걸음 수, 위치 n=A−B), 붉은 곡선 = 가우스 근사. 대칭 random walk(p=1/2)에서는 분산이 $Var(X_k)=k\Delta x^2=$**2Dt**이다. 여기서 $t=k\Delta t$, $D=\Delta x^2/(2\Delta t)$이다. 따라서 random walk와 확산 방정식의 Gaussian 해는 분산이 일치한다. 다만 유한한 k에서의 random walk 분포는 이산적이며, Gaussian 분포와의 일치는 연속 극한에서 성립하고 유한한 스텝 수에서는 근사로 이해해야 한다. 분산이 t에 **선형**으로 커지는 것을 k를 움직여 확인.

k와 위치의 홀짝이 같은 칸에만 걸음꾼이 있다 (k+n 이 홀수면 확률 0).

continuous limit과 heat equation

- 이산 random walk를 연속 극한으로: $\Delta t \to 0$, $\Delta x \to 0$, $n \to \infty$, $t = n\,\Delta t$, x는 위치 변수, $D = \Delta x^2/(2\Delta t)$를 일정하게 유지
- **Markov property**: 미래 상태의 조건부 분포는 현재 상태가 주어지면 과거 경로에 추가로 의존하지 않는다. 즉, 현재 위치를 알면 그 이전에 어떤 경로로 도달했는지는 다음 스텝의 조건부 분포를 결정하는 데 추가 정보가 되지 않는다. 대칭 random walk에서는 현재 위치 x의 확률이 직전 시점의 양쪽 이웃 위치에서 각각 절반씩 전달되므로, 전이는 다음과 같다:

$$P(x,t) = \tfrac{1}{2}P(x+\Delta x,\ t-\Delta t) + \tfrac{1}{2}P(x-\Delta x,\ t-\Delta t)$$

- 양변을 Taylor expansion하면

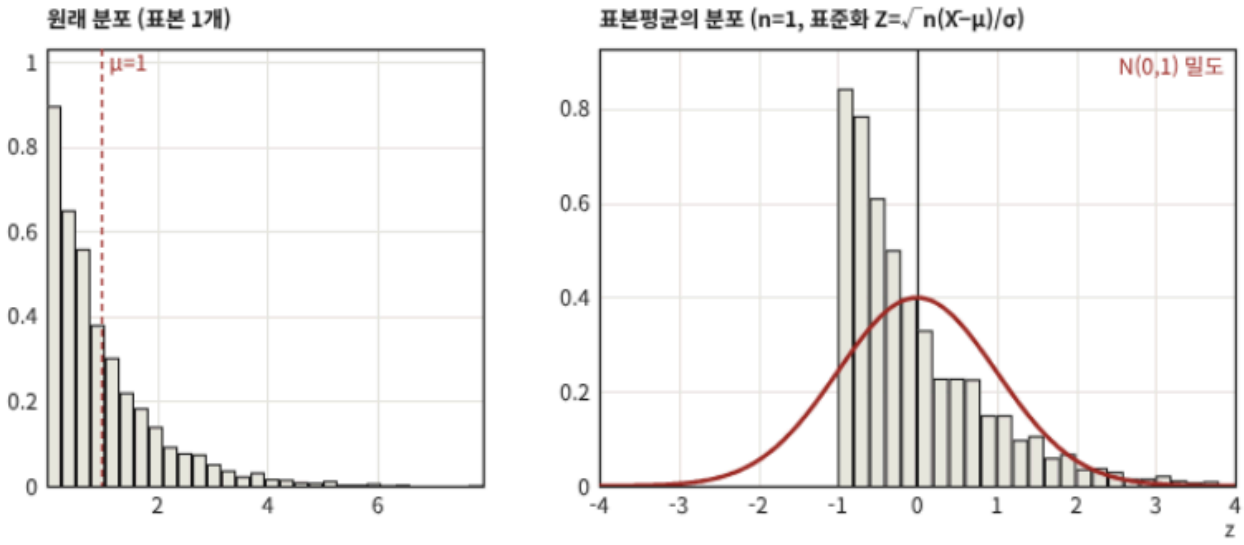
$$\frac{\partial P}{\partial t} = D\,\frac{\partial^2 P}{\partial x^2} \qquad (\text{heat / diffusion equation})$$

- 초기조건: 모든 입자가 $x = 0.\ t > 0$에서 이 PDE를 푼다

해의 성질: 평균과 분산

- 확산 PDE의 해는 **Gaussian**
- 평균: $\int_{-\infty}^{\infty} x\,P(x,t)\,dx = 0$. 0에서 출발한 대칭 random walk와 일치
- 분산: $\int_{-\infty}^{\infty} x^2\,P(x,t)\,dx = 2Dt -$ 선형 성장 ($D = 1$이면 $2t$). $\frac{\partial P}{\partial t} = D\frac{\partial^2 P}{\partial x^2}$와 integration by parts으로 유도
- 이산 시뮬레이션과 일치: 평균은 0에 머물고 퍼짐(분산)은 시간에 따라 증가
- 금융수학에서는 **Brownian motion** / Wiener process

왜 가우스 모양인가: 표준화한 합의 분포 (CLT)



기본값: 표본 크기 n 1

---

n = **1** (M=2500번 반복) | Z의 표본평균 0.007 (이론 0), 표준편차 0.974 (이론 1) | 왜도 1.792 (이론 γ/√n = 2.000) | N(0,1)과의 최대 CDF 차이 **0.159**

원래 분포가 어떤 모양이든(치우침·불연속) n이 커지면 표준화한 평균의 분포가 N(0,1)로 간다. 치우친 분포(지수, 베르누이)는 n이 작을 때 왜도가 남고 √n에 반비례로 줄어든다. 동전(±1)의 n번 합 = random walk의 위치 (주제 8).

CLT 적용 조건: 독립·동일분포인 확률변수들이 유한한 평균 μ와 양의 유한한 분산 σ^2을 가지면, 적절히 표준화한 표본평균은 $n\to\infty$에서 N(0,1) 분포로 수렴한다. 원래 분포가 비대칭이거나 이산형이어도 성립할 수 있다. 왜도가 $\gamma/\sqrt{n}$으로 감소한다는 관계는 독립·동일분포 표본에서 분산이 유한하고 3차 절대 모멘트도 유한할 때 적용된다.