문제 5

SIR 모형: $S(0) = 39, I(0) = 1, R(0) = 0, N = 40$. β, γ는 각각 $[1/15, 1/3]$, $[1/14, 1/7]$ 위 독립 균일변수. 두 구간을 각각 $M = 30$개로 등분한다.

a. 각 (β_i, γ_j) 조합별로 SIR 방정식을 풀어 S, I의 $t = 10, 20, 30, 40, 50$에서의 값을 구하여라(학습/시험 자료).

b. AI 모델에게 요청해, 입력이 $[S(10), \dots, S(50), I(10), \dots, I(50)]$(10개)이고 출력이 $[\beta, \gamma]$인 단일 은닉층 신경망(은닉 뉴런 예: 100개, sigmoid 활성화)을 작성하라. 손실은 $\text{Loss} = \sum_{k=1}^{m} [(\beta_k - \hat{\beta}_k)^2 + (\gamma_k - \hat{\gamma}_k)^2]$.

c. 자료의 80%로 학습하고 20%로 시험하여 β와 γ의 평균 예측 정확도를 계산하라.

d. 시험 자료로 β vs $\hat{\beta}$, γ vs $\hat{\gamma}$ 그래프를 그리고 각각의 Pearson 상관계수를 구하라.

e. β와 γ 중 무엇이 더 추정하기 어려운지, 왜인지 논하고 정확도 개선 방법을 논하라.

유형: AI 도구 + 구현 문제 · 데이터 생성(RK) → 네트워크 설계 → 학습/평가 순서를 먼저 세우는 문제

힌트 ▾

- 역문제: 궤적 (S, I)에서 파라미터 (β, γ)를 거꾸로 추정.
- 데이터 생성의 정확도가 전체 정확도의 바닥. 입력 표준화로 sigmoid 포화 방지.

정답 ▾

코드는 Claude로 작성했다.

STEP 1 **(a) 데이터 생성: 수업 코드의 RK3 오류 수정**

- β_i, γ_j를 각 구간에서 30개씩 등간격으로 잡아 900개 조합을 만들고 SIR 방정식을 풀어 $t = 10, 20, 30, 40, 50$의 S, I를 저장했다.
- **그런데 수업 코드(Day6)**의 3차 Runge-Kutta는 둘째, 셋째 단계에서 Δt 앞의 계수 $\frac{1}{4}$, $\frac{2}{3}$이 빠져 있어서 표준 SSP-RK3로 고쳐서 썼다.
- 고친 결과를 solve_ivp 고정밀 해와 비교하면 900개 조합 전체에서 최대 절대오차가 5.5×10^{-3}명.
- $\Delta t = 0.1$로 줄이면 오차가 약 10^{-3}배로 줄어 3차 정확도도 확인된다.
- 수업 코드를 그대로 쓰면 Δt를 줄여도 오차가 줄지 않았고, $\beta = 1/3, \gamma = 1/14$에서는 최대 18명까지 차이가 났다.

STEP 2 **(b) 네트워크 구성**

- 입력 10개를 학습 자료의 평균과 표준편차로 표준화하고, 은닉층 하나(sigmoid 뉴런 100개)와 선형 출력층 2개로 구성했다.
- 역전파와 Adam을 numpy로 구현해 전체 학습 자료로 20000번 갱신했다.
- 학습률을 10^{-3}으로 고정하면 손실이 오르내려서 10^{-5}까지 지수적으로 줄였다.

STEP 3 **(c) 학습/시험 분할과 정확도**

격자 자료 900개를 무작위로 80:20 분할하여 격자 내부의 예측 성능을 평가했다. 인접한 매개변수 조합이 학습·시험 자료에 나뉘어 들어갈 수 있으므로, 일반화 성능을 추가 검증하려면 일부 매개변수 구간을 통째로 시험 자료로 분리하는 평가도 수행한다. 평균 절댓값 상대오차를 MAPRE = (1/m)Σ |θ̂_k − θ_k| / θ_k 로 정의하고, 편의상 예측 점수를 100(1 − MAPRE)%로 계산했다. 이는 표준화된 정확도 지표가 아니라 본 실험에서 정의한 점수다.

	평균 상대오차	평균 절대오차	정확도
β	0.40%	4.93×10^{-4}	99.60%
γ	0.49%	5.26×10^{-4}	99.51%

마지막 학습 손실은 6.6×10^{-4}, 시험 손실은 2.4×10^{-4}였다.

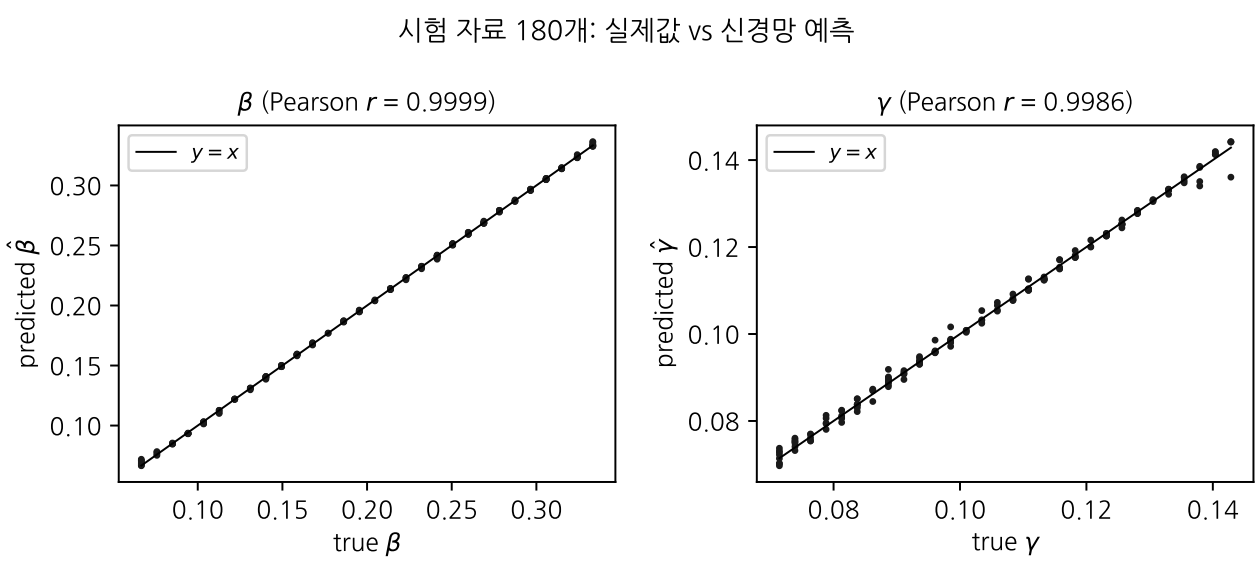
STEP 4 **(d) 산점도와 상관계수**

시험 자료 180개에 대해 Pearson 상관계수는 $r_\beta = 0.99996, r_\gamma = 0.99923$이다. 아래 그림은 같은 절차를 재실행한 결과다. 신경망 학습은 초기화와 배치 구성이 확률적이라, 재실행하면 상관계수가 조금 달라진다(아래 (d)의 수치는 재실행 결과).

STEP 5 (e) 무엇이 더 어려운가, 왜

- γ가 더 어려웠다.
- 평균 상대오차와 절대오차 모두 γ가 더 크고 상관계수도 더 낮다.
- γ의 절대 구간 폭이 좁기 때문이다. γ 구간은 [1/14, 1/7]로 폭이 1/14≈0.071이고, β 구간은 [1/15, 1/3]로 폭이 4/15≈0.267이라 절대 구간 폭의 비는 약 3.7배이다. 다만 상대 구간 폭은 γ가 2배, β가 5배로 β 쪽이 더 크다. 구간 폭만으로 추정 난이도를 단정할 수는 없으며, 출력 민감도와 정보량을 함께 봐야 한다.
- 또 $S' = -\beta SI/N$이라 S는 γ의 영향을 I를 거쳐서만 받으므로, 입력 중 S 값 5개에는 γ에 대한 정보가 적다.
- 시험 자료를 초기에 감염자가 늘어나는지에 따라 나눠 보았다.
- 이 초기조건에서는 $S/N = 39/40$이므로 감염자가 늘어나는 기준은 $R_0 > 1$보다 $I'(0) > 0$, 즉 $\frac{39}{40}\beta > \gamma$로 보는 것이 정확하다.
- $\frac{39}{40}\beta < \gamma$이면 S는 거의 39에 머물고 I는 대략 $e^{(\frac{39}{40}\beta-\gamma)t}$로 줄어서, 자료가 거의 $\frac{39}{40}\beta - \gamma$ 값 하나로 정해진다. 정확히는 $S_0 \approx N$ 조건에서 $I(t)/I(0) = \exp((\beta S_0/N - \gamma)t)$이며 부호는 $\beta S_0/N - \gamma$가 정한다. $\beta < \gamma$인 전 범위에서는 이 지수가 음수라 지수 감소가 일어난다.
- 그래서 β와 γ를 따로 구하기 어렵다.
- 이런 자료 35개의 평균 상대오차는 β 1.24%, γ 1.09%로, 나머지 145개(β 0.20%, γ 0.35%)보다 β는 약 6배, γ는 약 3배 컸다.

정확도를 높이려면: $t < 10$인 이른 시점의 관측이나 $R(t)$를 입력에 추가해 회복 속도에 대한 정보를 더 주는 방법이 있다. 감염자가 줄어드는 영역에 학습 자료를 더 넣는 것도 방법이다.



(d) 시험 자료 180개의 실제값 vs 예측값 (같은 절차 재실행, rβ = 0.9999, rγ = 0.9986)

γ가 더 어렵다. 범위가 좁아 자료가 덜 변하고, S에는 γ 정보가 간접적으로만 들어있다.